# 추천 시스템 설계하기 [프로젝트]

▼ 데이터셋 소개

데이터셋 링크: Amazon Sales Dataset

▼ 데이터셋 구조

필드명	설명
product_id	제품의 고유 식별자
product_name	제품의 이름
category	제품이 속한 카테고리 정보
discounted_price	할인된 가격
actual_price	정가
discount_percentage	할인율
rating	제품의 평균 평점
rating_count	제품에 대한 총 평점 수
about_product	제품에 대한 간단한 설명
user_id	리뷰를 작성한 사용자의 고유 식별자 (쉼표로 구분된 여러 사용자)
user_name	리뷰를 작성한 사용자 이름 (쉼표로 구분된 여러 사용자)
review_id	리뷰의 고유 식별자 (쉼표로 구분된 여러 리뷰)
review_title	리뷰 제목 (쉼표로 구분된 여러 리뷰 제목)
review_content	리뷰 내용 (쉼표로 구분된 여러 리뷰 내용)
img_link	제품 이미지 URL
product_link	제품 페이지 URL

# 데이터 샘플

첫 번째 상품 예시:

• 제품명: Wayona Nylon Braided USB to Lightning Fast Charging Cable

• 카테고리:

Computers&Accessories|Accessories&Peripherals|Cables&Accessories|Cables|USBCables

• **할인가**: ₹399.00

• **정가**: ₹1,099.00

• **할인율**: 64%

• **평점**: 4.2

• 리뷰 수: 24,269

#### ▼ 최고 할인율 기반, 할인율이 가장 높은 상품 10개 찾기

# SELECT product\_name, discounted\_price, CAST(REPLACE(REPLACE(CAST(discounted\_price AS STRING), '₹', ''), ',', '') AS FLOAT64) A FROM `modulabs-project-465302.SQL\_project.amazon\_sales\_dataset` ORDER BY CAST(REPLACE(CAST(discount\_percentage AS STRING), '%', '') AS FLOAT64) DESC LIMIT 10;

행 //	product_name ▼	rating ▼	rating_count ▼
1	AmazonBasics Flexible Premium HDMI Cable (Black, 4K@60Hz, 18Gbps), 3-Foot	4.4	426973
2	Amazon Basics High-Speed HDMI Cable, 6 Feet - Supports Ethernet, 3D, 4K video,Black	4.4	426973
3	Amazon Basics High-Speed HD	4.4	426973
4	AmazonBasics Flexible Premium HDMI Cable (Black, 4K@60Hz, 18Gbps), 3-Foot	4.4	426972
5	boAt Bassheads 100 in Ear Wired Earphones with Mic(Taffy Pink)	4.1	363713
6	boAt Bassheads 100 in Ear Wired Earphones with Mic(Furious Red)	4.1	363713
7	boAt BassHeads 100 in-Ear Wir	4.1	363711
8	Redmi 9A Sport (Coral Green, 2GB RAM, 32GB Storage)   2GHz Octa-core Helio G25	4.1	313836

# 1. SELECT 절

```
SELECT product_name, discounted_price,
```

- product\_name : 상품 이름
- discounted\_price : 할인된 가격
- ...: 아래에서 설명할 **숫자로 변환된 가격** (계산용 score 컬럼)

#### 2. CAST(REPLACE(...)) AS score

CAST(REPLACE(REPLACE(CAST(discounted\_price AS STRING), '₹', ''), ',', '') AS FLOAT64) AS score

- discounted\_price 는 원래 ₹13,999 같은 **문자 형태**임
- 이걸 숫자로 바꾸려면:
  - 1. CAST(... AS STRING): 먼저 문자열로 변환
  - 2. REPLACE(..., '₹', ''): ₹ 기호 제거
  - 3. REPLACE(..., '', '') : 쉼표 제거
  - 4. CAST(... AS FLOAT64): 숫자로 변환

# 3. ORDER BY 절

#### **ORDER BY**

CAST(REPLACE(CAST(discount\_percentage AS STRING), '%', '') AS FLOAT64) DESC

- discount\_percentage 값은 '64%', '43%' 같은 형태
- 이걸 숫자 비교하려면:
  - 1. 문자열로 변환
  - 2. 🦋 기호 제거
  - 3. 숫자(Float)로 변환
- DESC: 할인율 높은 순서로 정렬

#### ▼ 리뷰 수가 많은 인기 제품 추천

```
SELECT

product_name,

rating,

rating_count

FROM `modulabs-project-465302.SQL_project.amazon_sales_dataset`

WHERE

REGEXP_CONTAINS(rating, r'^[0-9.]+$')

AND CAST(rating AS FLOAT64) >= 4.0

ORDER BY

CAST(REPLACE(CAST(rating_count AS STRING), ',', '') AS INT64) DESC

LIMIT 10;
```

//	//	//	//	//
1	B0B4KPCBSH	IKEA Frother for Milk	Home&Kitchen Kitchen&Hom eAppliances Coffee,Tea&Espr esso CoffeeGrinders ElectricG rinders	244.0
2	B009LJ2BXA	Hp Wired On Ear Headphones With Mic With 3.5 Mm Drivers, In-Built Noise Cancelling, Foldable And Adjustable For Laptop/Pc/Office/Home/ 1	Computers&Accessories Acce ssories&Peripherals Audio&Vi deoAccessories PCHeadsets	649.0
3	B00MFPCY5C	GIZGA essentials Universal Silicone Keyboard Protector Skin for 15.6-inches Laptop (5 x 6 x 3 inches)	Computers&Accessories Acce ssories&Peripherals Keyboard s,Mice&InputDevices Keyboar d&MiceAccessories DustCove rs	39.0
4	B097JVLW3L	Irusu Play VR Plus Virtual Reality Headset with	Electronics HomeTheater,TV&Vi	2699.0

# 1. SELECT 절

SELECT product\_name, rating, rating\_count

#### • 출력할 컬럼:

o product\_name : 상품 이름

o rating : 평점

o rating\_count : 리뷰 수

# 2. WHERE 절

```
WHERE
REGEXP_CONTAINS(rating, r'^[0-9.]+$')
AND CAST(rating AS FLOAT64) >= 4.0
```

- REGEXP\_CONTAINS(rating, r'^[0-9.]+\$')
  - → 숫자와 소수점(.)만 포함된 평점 값만 필터링
  - → 예외 값들 (예: 'l', 'N/A', null ) 제거
- CAST(rating AS FLOAT64) >= 4.0
  - → 필터링된 값 중에서 **평점이 4.0 이상**인 데이터만 선택
- 📌 이 조합을 통해 쿼리가 실패하지 않고 안전하게 실행됨

#### 3. ORDER BY 절

#### **ORDER BY**

CAST(REPLACE(CAST(rating\_count AS STRING), ',' '') AS INT64) DESC

- rating\_count 는 "43,994" 처럼 문자열로 되어 있으므로:
  - 1. CAST(... AS STRING) → 문자열로 변환
  - 2. REPLACE(..., ',' ") → 쉼표 제거
  - 3. CAST(... AS INT64) → 정수로 변환
- DESC: 리뷰 수가 많은 순으로 내림차순 정렬
- ▼ 카테고리별 베스트 추천

```
SELECT *
FROM (
SELECT *,
ROW_NUMBER() OVER (
PARTITION BY category
ORDER BY CAST(rating AS FLOAT64) DESC
) AS rank
FROM `modulabs-project-465302.SQL_project.amazon_sales_dataset`
WHERE REGEXP_CONTAINS(rating, r'^[0-9.]+$') -- 숫자/소수점만 있는 평점만 필터링
) ranked
WHERE rank = 1;
```

1	product_id ▼	product_name ▼ //	category ▼ //	discounted_price 🔻 a
1	B0B4KPCBSH	IKEA Frother for Milk	Home&Kitchen Kitchen&Hom eAppliances Coffee,Tea&Espr esso CoffeeGrinders ElectricG rinders	244.0
2	B009LJ2BXA	Hp Wired On Ear Headphones With Mic With 3.5 Mm Drivers, In-Built Noise Cancelling, Foldable And Adjustable For Laptop/Pc/Office/Home/ 1	Computers&Accessories Acce ssories&Peripherals Audio&Vi deoAccessories PCHeadsets	649.0
3	B00MFPCY5C	GIZGA essentials Universal Silicone Keyboard Protector Skin for 15.6-inches Laptop (5 x 6 x 3 inches)	Computers&Accessories Acce ssories&Peripherals Keyboard s,Mice&InputDevices Keyboar d&MiceAccessories DustCove rs	39.0
4	B097JVLW3L	Irusu Play VR Plus Virtual Reality Headset with	Electronics HomeTheater,TV&Vi	2699.0

#### 1. REGEXP\_CONTAINS(rating, r'^[0-9.]+\$')

- rating 값이 숫자(예: 4.3, 5.0)로만 이루어진 경우만 선택합니다.
- 이유: 데이터에 🍟 같은 이상한 문자가 섞여 있어 에러 방지용입니다.

### 2. ROW\_NUMBER() OVER (...) AS rank

```
ROW_NUMBER() OVER (
PARTITION BY category
ORDER BY CAST(rating AS FLOAT64) DESC
)
```

- category 별로 데이터를 **그룹(분리)** 합니다.
- 각 그룹 안에서 평점(rating)이 높은 순서대로 번호(rank) 를 매깁니다.

#### 3. WHERE rank = 1

- 각 카테고리에서 순위가 1인 상품, 즉 평점이 가장 높은 상품만 골라냅니다.
- ▼ 가성비 추천 (평점/가격 비율 기준)

```
SELECT product_name, rating, discounted_price
FROM `modulabs-project-465302.SQL_project.amazon_sales_dataset`
WHERE
REGEXP_CONTAINS(rating, r'^[0-9.]+$') AND
```

rating IS NOT NULL AND
discounted\_price IS NOT NULL

ORDER BY

CAST(rating AS FLOAT64) /

CAST(REPLACE(REPLACE(CAST(discounted\_price AS STRING), '₹', ''), ',', '') AS FLOAT64) D

LIMIT 10;

행 //	product_name ▼	rating ▼	discounted_price 🕶
1	E-COSMOS 5V 1.2W Portable Flexible USB LED Light (Colours May Vary, Small, EC-POF1)	3.8	39.0
2	Inventis 5V 1.2W Portable Flexible USB LED Light Lamp (Colors may vary)	3.6	39.0
3	GIZGA essentials Universal Silicone Keyboard Protector Skin for 15.6-inches Laptop (5 x 6 x 3 inches)	3.5	39.0
4	Classmate Octane Neon- Blue Gel Pens(Pack of 5) Smooth Writing Pen Attractive body colour for Boys & Girls Waterproof ink for	4.3	50.0
5	FLiX (Beetel Flow USB to	4.0	57.89

# 1. WHERE 절

#### WHERE

REGEXP\_CONTAINS(rating, r'^[0-9.]+\$') AND rating IS NOT NULL AND discounted\_price IS NOT NULL

- 평점 값이 정상 숫자 형식(예: 4.2, 3.8) 인 경우만 선택
- 평점 또는 할인 가격이 NULL인 상품은 제외

# 2. ORDER BY 절


#### **ORDER BY**

CAST(rating AS FLOAT64) /

CAST(REPLACE(REPLACE(CAST(discounted\_price AS STRING), '₹', ''), ',', '') AS FLOAT64) D

- rating 을 숫자로 변환
- discounted\_price 에서:
  - ㅇ ₹ 기호 제거
  - 기쉼표 제거
  - 。 → 숫자로 변환
- 평점을 가격으로 나눈 값이 큰 순서대로 정렬 (**가성비 점수**)
- ▼ 리뷰 내용 기반 키워드 추천

SELECT product\_name, review\_content
FROM `modulabs-project-465302.SQL\_project.amazon\_sales\_dataset`
WHERE
REGEXP\_CONTAINS(rating, r'^[0-9.]+\$') AND
CAST(rating AS FLOAT64) >= 4.0 AND
LOWER(review\_content) LIKE '%durable%'
LIMIT 10;



# 1. WHERE 절

#### WHERE

REGEXP\_CONTAINS(rating, r'^[0-9.]+\$') AND CAST(rating AS FLOAT64) >= 4.0 AND LOWER(review\_content) LIKE '%durable%'

- rating 값이 숫자나 소수점으로만 이루어진 경우만 필터링
   → | 같은 이상한 값 걸러내기 (에러 방지용)
- 평점을 숫자로 변환하고, 4.0 이상인 상품만 선택
- 리뷰 내용에 "durable" 이라는 단어(소문자 기준)가 포함된 경우 → 즉, 사용자들이 "튼튼하다", "잘 안 망가진다" 는 말을 직접 했다는 뜻